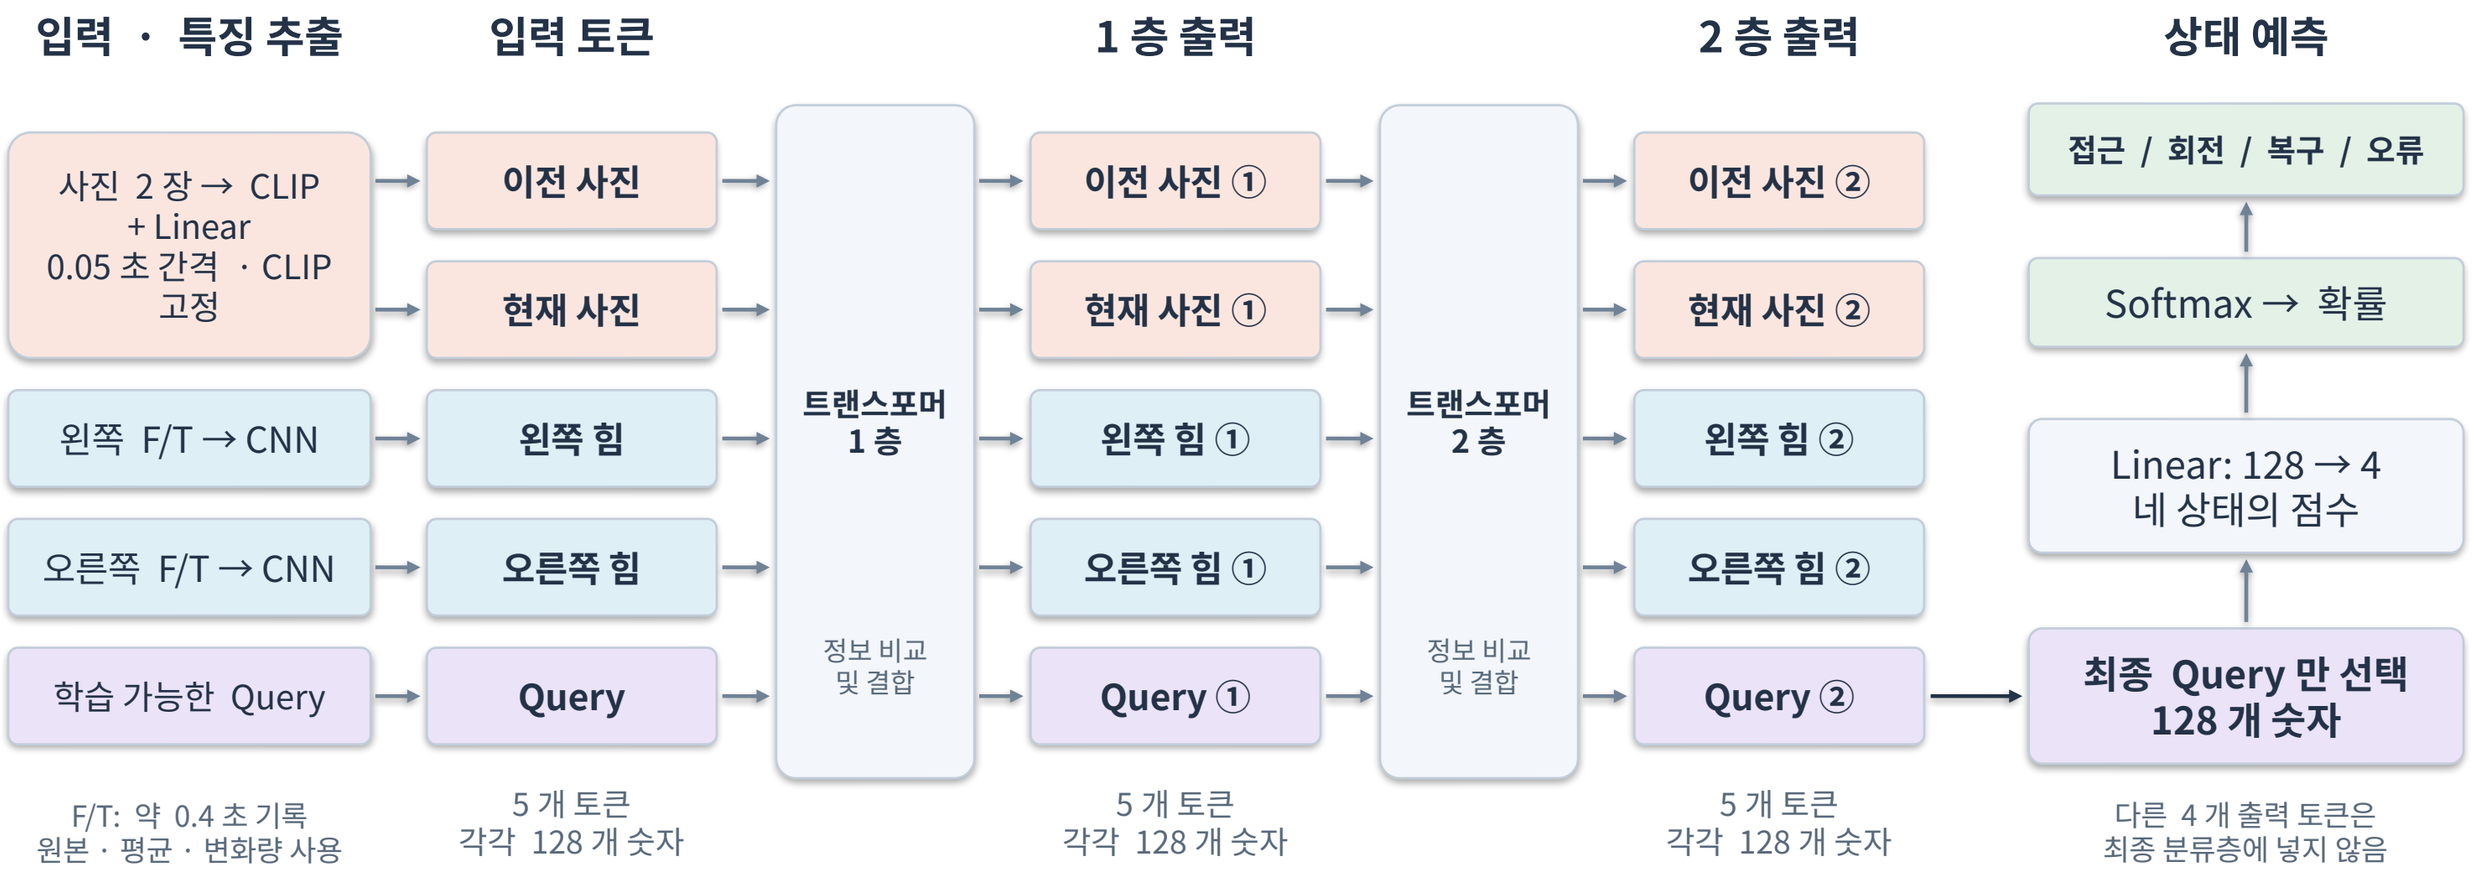
사진과 힘의 정보가 두 Transformer 층을 거쳐 Query 에 모이는 과정

입력 5 개 → 1 층 출력 5 개 → 2 층 출력 5 개 → 최종 Query 하나로 상태 예측



①·② 는 각 층에서 갱신된 특징을 뜻함 | 사진과 힘의 정보가 반영된 최종 Query 로만 분류

학습 : 현재 시점의 정답 라벨과 예측을 비교하여 오차 최소화 · Query 는 정답 라벨이 아님

시간 기준 : RGB 60 fps / F/T 100 Hz. 종류 · 위치 임베딩과 Transformer 내부 연산은 생략 . 각 층에서의 정보 교환은 causal attention mask 를 따름 .